

LeCun의 JEPA와 세계 모델

LLM 너머의 로봇 지능을 향해

Giseop Kim

APRL, DGIST

오늘 다룰 것

1. **LeCun의 도발**: JEPA가 무엇이고 왜 주목해야 하는가
2. **역사: CNN → 자기지도학습**: 라벨 병목과 케이크 슬라이드
3. **LLM의 탄생**: 트랜스포머와 다음 토큰 예측이 성공한 이유
4. **흐릿함의 문제**: 왜 생성형 방식이 영상에서 실패했나
5. **결합 임베딩과 삼 신경망**: 생성 없이 표현 배우기
6. **표현 붕괴와 Barlow Twins**: 게으른 답을 막는 법
7. **DINO 계열**: 자기지도학습이 지도학습을 따라잡다
8. **JEPA 아키텍처**: 결합 임베딩 + 예측기 = 세계 모델
9. **전망**: JEPA가 LLM을 대체할 것인가

전제 지식: Transformer 기초, CNN, 임베딩 개념, 확률 분포

Part 1. LeCun의 도발과 JEPA

10억 달러짜리 베팅: 한 마디에서 시작하다

LeCun의 도발 (2024)

“에이전트 시스템을 만들겠다면서, 자기 행동의 **결과를 예측할 능력조차 없는** 시스템을 떠올린다는 게 도무지 이해가 안 됩니다.”

LLM의 근본 한계 (LeCun 시각)

- LLM은 언어를 잘 다루지만, 그게 전부
- 물리 세계를 **모델링하지 않음**
- 자기 행동의 결과를 사전에 **예측 불가**
- “après moi, le déluge” (행동 후 결과는 모름)

그의 베팅

- Meta 수석 AI 과학자 역임
- 최근 10억 달러 조성
- **LLM 백본 없는** AI 추구
- 핵심 아이디어: **JEPA**

“LLM이 VLA를 대체할까?”




“결국 LLM은 대체될 것”

JEPA: 아이디어의 핵심

JEPA = Joint Embedding Predictive Architecture

기존 ML의 공식: 입력 $X \rightarrow$ 출력 Y 직접 예측



Part 2. CNN에서 자기지도학습까지


LeCun의 역사: 혁명을 두 번 예감한 사람

1989년: CNN 개척

- 대부분은 전문가 시스템에 집중 (규칙 기반)
- LeCun: 데이터에서 직접 학습 주장
- LeNet으로 손글씨 인식 구현
- AT&T 수표 판독 시스템에 실제 배포

2012년: AlexNet과 딥러닝 부흥

- LeCun의 CNN과 놀라울 만큼 유사
- ImageNet top-5 오류율: 26.2% → 15.3%
- 전문가 시스템의 시대 종언



라벨 병목: 지도학습의 한계

AlexNet의 성공 공식

대용량 데이터(ImageNet) + CNN + GPU → 성능 돌파

치명적 의존성: ImageNet의 모든 이미지에는 **사람이 직접 붙인 라벨**이 있다.

사람 아이

- “강아지” 개념 학습에
명시 라벨 **거의 필요 없음**
- 몇 번 보면 일반화
- 자율적으로 개념 형성

딥러닝 모델

- 수십만 개 라벨 이미지 필요
- 라벨 수집 = 비용·시간 병목
- 라벨 없는 데이터는 버림

방향의 전환

라벨 없이 스스로 학습하는 **자기지도학습(self-supervised learning)**으로 눈을 돌림.

LeCun의 케이크 슬라이드 (2015~)



LeCun의 예언 (2015)

- 자기지도학습이 핵심 엔진이 될 것
- RL만으로는 인간 수준 불가
- 실제로 이 순서로 성공

아이러니

- 자기지도학습이 언어에서 먼저 폭발
- 비전이 아닌 텍스트에서 LLM 탄생
- 왜? → 다음 Part에서


Part 3. LLM의 탄생: 다음 토큰 예측

트랜스포머와 GPT-1 (2018)

OpenAI의 전략 전환

- 초기: 강화학습 중심 (Gym, Universe, 아타리)
- 수츠케버·래드퍼드: Google의 **트랜스포머**에 주목 (원래 기계 번역용)

핵심 아이디어: 자기지도 사전학습



결과: 9개 언어 벤치마크에서 새 SOTA

— 과제별로 설계된 전문 모델들을 모두 제침

GPT-1이 열어준 것

사람이 만든 라벨 없이, **인터넷의 모든 텍스트**를 학습 신호로 쓸 수 있게 됨

⇒ 전례 없는 **스케일링**의 문이 열림

GPT 스케일링: 2012→2020

모델	연도	파라미터	학습 예시 수
AlexNet	2012	60 M	~1 M
GPT-1	2018	117 M	~1 B (토큰)
GPT-2	2019	1.5 B	~40 B
GPT-3	2020	175 B	~300 B
ChatGPT 기반	2022	175 B+	+RLHF fine-tune

학습 패러다임: LeCun의 케이크와 정확히 일치

1. **자기지도 사전학습** (다음 토큰 예측, 방대한 텍스트)
2. **지도학습 fine-tune** (라벨 달린 소량 데이터)
3. **강화학습** (RLHF: 인간 피드백으로 정렬)

아이러니: LeCun이 그린 그림이 **비전이 아닌 언어에서** 먼저 실현. 왜 비전은 달랐는가? → 다음 Part.

사전학습이 배운 것의 본질

다음 토큰 예측 자체는 프록시 태스크(proxy task)에 불과하다.

진짜 가치: 이 과제를 잘 풀기 위해 모델 내부에 형성된 **표현(representation)**

프록시 태스크

- “다음 단어가 뭐지?”
- 겉보기에 단순한 자동완성
- 그러나 이것을 잘 하려면...

내부에서 학습된 것

- 인과 관계, 사실 지식
- 논리 추론, 유추
- 코딩, 수학 등 고차 능력

핵심 통찰

생성 능력 자체보다 **학습된 내부 표현**이 LLM 성공의 진짜 원천.
그렇다면 생성 없이도 좋은 표현을 얻을 수 있지 않을까?

Part 4. 영상의 흐릿함 문제

픽셀 생성: 왜 영상은 텍스트와 다른가

GPT 방식을 영상에 그대로 적용하면?

비디오 프레임 시퀀스 $f_1, f_2, \dots, f_t \rightarrow$ 다음 프레임 f_{t+1} 예측 (픽셀 단위)

언어의 출력 공간

- 고정된 어휘: GPT-2 기준 50,257 개의 이산 토큰
- 각 토큰에 독립적 확률 부여 가능
- “왼쪽” 40%, “오른쪽” 40%, “위” 20% $\rightarrow$ OK

영상의 출력 공간

- Full HD: $1920 \times 1080 \times 3$ 픽셀, 각 픽셀 $\in [0, 255]$
- 가능한 다음 프레임 수: $\approx 256^{1920 \times 1080 \times 3} = 10^{15,000,000}$
- 관측 가능한 우주의 원자 수: $\approx 10^{80}$
- 완전 열거 불가능

평균화 = 흐릿함

실제 구현: 픽셀 강도를 신경망이 실수값으로 직접 예측 (회귀)

불확실성 앞에서 손실을 최소화하는 가장 쉬운 답:

$$\hat{f}_{t+1} = \mathbb{E}[f_{t+1} \mid f_1, \dots, f_t] \quad (\text{가능한 결과들의 평균})$$

언어 모델 (“공이 __로 갔다”)

- 토큰이 분리됨
- “왼쪽” 확률 $\uparrow$, “오른쪽” 확률 $\uparrow$
- 두 가능성 독립적 갱신 가능
- 결과: 명확한 분포

영상 모델 (공이 어느 방향으로?)

- 하나의 출력 프레임 직접 예측
- 왼쪽 공 + 오른쪽 공 **픽셀 평균**
- 결과: 공이 두 곳에 반쯤 있는 이미지
- **흐릿하고 비현실적**


근본적 질문

꼭 생성형 아키텍처여야 하는가? 좋은 **내부 표현**을 생성 없이 얻을 수 없는가?


Part 5. 결합 임베딩과 삼 신경망

비생성적 표현 학습: 아이디어의 전환

생성형 (GPT 방식)



결합 임베딩 (JEPA 방향)



핵심

픽셀을 재구성하지 않고, **임베딩 공간에서 예측.**

흐릿함 문제를 **원천 회피**: 추상 표현 수준에서만 예측 오차를 정의.

삼 신경망: 1990년대의 원조


배경: 1990년대 초 LeCun, Bell Labs — 위조 서명 검출

구조

- 같은 가중치 공유하는 **두 개 복제 네트워크**
- 입력: 이미지 쌍 (서명 두 장)
- 출력: 임베딩 벡터 한 쌍 (이미지 생성 아님)

학습

- 양성 쌍: 같은 사람의 서명 → 임베딩 **비슷하게**
- 음성 쌍: 위조 서명 쌍 → 임베딩 **다르게**
- 손실: contrastive loss



통찰

“결합 임베딩”만으로 서명의 유용한 내부 표현 학습.
생성을 완전히 건너뛴다.

Part 6. 표현 붕괴와 그 해법

표현 붕괴: 가장 게으른 답

문제 설정: 원본 이미지와 변형 이미지의 임베딩이 비슷해지도록 학습

네트워크 입장에서 가장 쉬운 답:

$$f(x) = \mathbf{c} \quad \forall x \quad (\text{모든 입력에 동일한 상수 벡터 출력})$$

모든 입력에 $[1, 1, \dots, 1]$ 을 출력하면?

- 같은 이미지의 두 변형: $[1, \dots, 1]$ vs $[1, \dots, 1] \rightarrow$ 유사도 최대
- 손실 함수: 완전히 만족
- 모델이 배운 것: 아무것도 없음

이것이 **표현 붕괴(representation collapse)**.

초기 해법: 대조 학습(contrastive learning)

- 같은 장면의 다른 뷰: 임베딩 $\uparrow$ 유사
- 다른 이미지들: 임베딩 $\downarrow$ 달리
- 효과적이지만 대규모 음성 샘플 필요 $\rightarrow$ 계산 비용 급증

Barlow Twins: 뉴런 중복성을 줄여라

착안: 이론 신경과학자 **호러스 발로(Horace Barlow, 1961)**의 가설

발로의 가설

동물의 시각 시스템에서 뉴런들은 **서로 간의 중복 정보를 줄이는** 방향으로 작동한다.

아이디어 (Meta AI, 2021 — 스테판 데니): 이 원리를 네트워크 출력에 적용

교차상관 행렬 C 정의

$$C_{ij} = \frac{\sum_b z_{b,i}^A \cdot z_{b,j}^B}{\sqrt{\sum_b (z_{b,i}^A)^2} \cdot \sqrt{\sum_b (z_{b,j}^B)^2}}$$

배치 b 에 걸쳐 인코더 A의 i 번 뉴런과 인코더 B의 j 번 뉴런 사이의 **피어슨 상관계수**

목표: $C \approx I$ (단위 행렬)

- **대각 성분** = 1: 같은 이미지의 대응 뉴런 출력은 최대 일관성
- **비대각 성분** = 0: 서로 다른 뉴런들의 출력은 **중복 정보 없음**

Barlow Twins 손실 함수

$$\mathcal{L}_{BT} = \underbrace{\sum_i (1 - c_{ii})^2}_{\text{불변성 항}} + \lambda \underbrace{\sum_{i \neq j} c_{ij}^2}_{\text{중복성 항}}$$

불변성 항

- 대각 원소를 1로 당김
- 같은 이미지의 변형 쌍에 대해 같은 출력을 요구
- 표현 붕괴 쪽으로 **당기는 힘**

중복성 항

- 비대각 원소를 0으로 당김
- 뉴런들이 **서로 다른 정보** 인코딩하도록 강제
- 표현 붕괴를 **막는 힘**

핵심 장점

- 음성 샘플(negative pairs) **불필요** → 대조 학습의 한계 극복
- 배치 크기에 덜 민감
- 강력한 표현을 학습하면서도 붕괴 방지

Part 7. 표현 품질 측정과 DINO

선형 프로브: 표현 품질을 재는 도구

방법론: 사전학습 인코더 위에 단 **한 층**의 선형 분류기만 추가



이 테스트가 측정하는 것: “동결된 표현만으로, 선형적으로 분리 가능한 클래스 구조가 잡혀 있는가?”

모델	ImageNet top-1	학습 방식
AlexNet (2012)	59.3%	완전 지도학습
Barlow Twins (2021)	73.2%	자기지도 + 선형 프로브
ViT-L (구글, 2020)	88.6%	완전 지도학습 (새 SOTA)

Barlow Twins는 **라벨 0개**로 AlexNet(완전 지도)을 10%p 이상 앞섬.
그러나 2020년 지도학습 SOTA와는 여전히 15%p 격차.

VICReg → DINO: 자기지도학습이 따라붙다

Barlow Twins 이후의 흐름

- **VICReg** (Meta, 2022): Barlow Twins의 단순화 버전, 유사한 성능
- **DINO v1** (FAIR Paris, 2021): 지식 증류(knowledge distillation) 기반 결합 임베딩
- **DINO v2** (2023): 대규모 큐레이션 데이터 + 레시피 정교화
- **DINO v3** (2025. 8): **ImageNet top-1 88.4%** 달성

DINO v3의 의미

“자기지도 모델이 이미지 분류에서 지도학습 모델과 **견줄 만한 결과**를 낸 것은 이번이 처음이다.” — DINO v3 저자

DINO의 질적 특성: 각 이미지 패치에 임베딩 벡터 출력

- 손 위치 패치의 임베딩 ↔ 다른 패치 임베딩 유사도 시각화
- 라벨 없이도 **손, 공, 고양이, 배경**을 깔끔하게 분리
- 별도 세그멘테이션 학습 없이 **창발적 분할(emergent segmentation)**

Part 8. JEPA 아키텍처: 세계 모델로


왜 세계 모델인가: 운전하는 십대

LeCun의 질문 (2022 position paper)


“수백만 시간의 주행 데이터로 우리가 만들어 낼 수 있는 건 테슬라의 레벨 2 시스템 정도예요. 그런데 17살짜리는 **몇 시간 연습**으로 운전을 배웁니다. 왜?”

그의 답: 세계 모델(World Model)

- 동물은 물리 세계에 대한 **예측 모델**을 갖고 있음
- 자기 행동의 결과를 **사전에 시뮬레이션**
- 그 위에서 계획(planning)과 추론



기본 JEPA: 정적 입력 (I-JEPA 류)




stop_grad: 목표 인코더는 역전파로 학습되지 않음 (EMA 업데이트).

⇒ 표현 붕괴 방지의 또 다른 핵심 설계.

JEPA가 세계 모델이 되는 순간: 행동 조건화

V-JEPA 2: 비디오 + 로봇 제어 신호 조건화



예측기가 배우는 것: “제어 신호 a_t 가 임베딩 공간에서 상태를 어떻게 변화시키는가”

계획 사용: 목표 상태 이미지 $\rightarrow$ 목표 임베딩 s^* $\rightarrow$ 세계 모델에서 가상의 행동 시퀀스들을 시뮬레이션해 $\hat{s} \approx s^*$ 가 되는 시퀀스 선택

세계 모델 = 고전 최적 제어 + 학습된 표현

르쿤의 표현

“이건 **고전적 최적 제어**입니다. 1950년대 후반 소련, 1960년대 초 서구로 거슬러 올라가는.”

“**고전적이지 않은 부분**: 모델을 머신러닝으로 학습.

더더욱 고전적이지 않은 부분: 입력의 추상 표현까지 **함께** 학습.”

VLA와의 결정적 차이

- VLA: 행동 → 직접 출력
- JEPA WM: 행동 결과를 **사전 예측** + 최적화

	VLA	JEPA
백본	LLM	비생성 인코더
예측	행동 token	임베딩
계획	암묵적	명시적
세계 모델	없음	있음
모달리티	언어 편향	모달리티 무관

LeCun: “LLM도 VLA도 자기 행동의 결과를 사전에 예측하지 못한다. 그게 내가 불안한 이유다.”

Part 9. JEPA가 LLM을 대체할 것인가

진행자 Q

“JEPA 같은 세계 모델 기반 접근이 언젠가 LLM을 대체할 거라고 보세요?”

LeCun

“당분간은 서로 다른 문제를 풀 겁니다.”

진행자 Q

“결국에는 LLM을 대체한다는 말씀이시고요?”

LeCun

“네. LLM은 언어를 다루는 데 정말 능숙하지만, 사실상 그게 전부거든요.”

신뢰할 수 있는 에이전트의 조건

1. 행동 결과를 **사전에 예측**
2. 행동 시퀀스를 **계획**
3. 안전 가드레일을 **보장**

LeCun의 핵심 주장

“추론 과정 자체가, 단순한 자기회귀 예측이 아니라 **탐색(search)**이 되어야 한다. 그게 바로 세계 모델이다.”

1. Barlow Twins의 “중복성 줄이기” 원리는 생물학적으로 타당한가?
Sparse coding, Independent Component Analysis와의 관계는?
2. **stop_grad** 없는 JEPA는 왜 붕괴하는가? 이것이 Bootstrapping 문제와 어떻게 연결되는가?
3. DINO v3가 ImageNet top-1 88.4%를 달성했다. 그렇다면 어떤 태스크에서 자기지도학습이 지도학습보다 아직 열위인가? 그 이유는?
4. VLA와 JEPA World Model을 **하이브리드**로 결합하는 방법을 설계해 본다면?
예: π_0 의 Action Expert 대신 JEPA predictor를 쓸 수 있는가?
5. (APRL 연구 관점) SLAM이 이미 세계 모델의 일종(환경 지도 유지·업데이트)이라고 볼 수 있다.
JEPA-style 세계 모델과 classical SLAM의 차이와 보완점은?

1. **LeCun의 도발:** LLM은 세계 모델 없이 행동 결과를 예측하지 못함 → JEPA

2. **자기지도학습의 역사:**

- CNN(라벨) → 자기지도학습 필요성 → LLM에서 먼저 폭발 (다음 토큰 예측)
- 언어: 이산 어휘 → 생성이 잘 작동 / 영상: 연속 픽셀 → 평균 = 흐릿함

3. **결합 임베딩 학습:**

- 삼 신경망: 생성 없이 표현 학습 (1990s)
- 표현 붕괴 문제 → 대조 학습(한계) → Barlow Twins(교차상관 행렬 = I)
- DINO v3: 자기지도 = 지도학습 수준 (ImageNet 88.4%)

4. **JEPA 아키텍처:**

- 인코더 $\times 2$ + 예측기: latent space에서 예측
- 행동 조건화 → 세계 모델 → 고전 최적 제어 + 학습된 표현

5. **미래:** 단기 공존, 장기 대체 — 세계 모델이 없는 AI에 LeCun이 내기를 걸지 않는 이유

- LeCun (2022) “A Path Towards Autonomous Machine Intelligence” (JEPA position paper)
- LeCun et al. (1993) “Signature Verification Using a Siamese Time Delay Neural Network”
- Radford et al. (2018) “Improving Language Understanding by Generative Pre-Training” (GPT-1)
- Zbontar et al. (2021) “Barlow Twins: Self-Supervised Learning via Redundancy Reduction”
- Bardes et al. (2022) “VICReg: Variance-Invariance-Covariance Regularization for Self-Supervised Learning”
- Caron et al. (2021) “Emerging Properties in Self-Supervised Vision Transformers” (DINO v1)
- Oquab et al. (2023) “DINOv2: Learning Robust Visual Features without Supervision”
- Assran et al. (2023) “Self-Supervised Learning from Images with a Joint-Embedding Predictive Architecture” (I-JEPA)
- Bardes et al. (2024) “V-JEPA: Latent Video Prediction for Visual Representation Learning”
- Bardes et al. (2025) “V-JEPA 2: Self-Supervised Video Models Enable Understanding, Prediction and Planning”

다음 주: V-JEPA 2 구현 상세 및 VLA와의 실험 비교